

Υπολογιστική Νοημοσύνη

Ιωάννης Γ. Τσούλος

Τμήμα Πληροφορικής και τηλεπικοινωνιών
Πανεπιστήμιο Ιωαννίνων

2023

Περίληψη

- 1 Γενικές έννοιες
- 2 Κανονικοποίηση βαρών
- 3 Αλλαγή μεγέθους
- 4 Μάθηση βαρών με διαστήματα

Confusion matrix

- 1 Αν έχουμε N κατηγορίες τότε έχει διάσταση $N \times N$
- 2 C_{ij} = Πλήθος προτύπων που ενώ ανήκουν στην κατηγορία i ανατέθηκαν στην κατηγορία j
- 3 Άθροισμα στοιχείων κύριας διαγωνίου: Πόσα στοιχεία έχουν ταξινομηθεί σωστά
- 4 Άθροισμα των υπολοίπων στοιχείων: Πόσα στοιχεία έχουν ταξινομηθεί λάθος

Precision and Recall

$$\text{Precision: } p = \frac{tp}{tp+fp}$$

$$\text{Recall: } r = \frac{tp}{tp+fn}$$

Μέγεθος μοντέλου μάθησης


- Χρήση λίγων μονάδων επεξεργασία (μάθηση απλών συναρτήσεων - καλή γενίκευση)
- Χρήση πολλών μονάδων επεξεργασίας (μάθηση δύσκολων συναρτήσεων - κακή γενίκευση)

Υπεργενίκευση

- Πολύ καλή μάθηση των δεδομένων στο train set
- Πολύ κακή απόδοση στο σύνολο ελέγχου.
- Συνήθως προκαλείται όταν έχουμε πολλές μονάδες επεξεργασίας.

- Περιέχει δεδομένα που δεν ανήκουν στο σύνολο εκπαίδευσης ή ελέγχου
- Η εκπαίδευση γίνεται με τα δεδομένα στο σύνολο εκπαίδευσης
- Η εκπαίδευση σταματά όταν το σφάλμα στο validation set θα αρχίσει να αυξάνει.
- Προφανώς απαιτεί να έχουμε αρκετά δεδομένα στην διάθεσή μας.

Μάθηση με χρήση validation set (σχήμα)



- Αυξητικές τεχνικές. Ξεκινούν από μικρό αριθμό βαρών και σταδικά προσθέτουν.
- Μειωτικές τεχνικές. Ξεκινούν από μοντέλα με μεγάλο αριθμό βαρών και κακή γενίκευση και σταδιακά μειώνουν τον αριθμό τους(κλάδεμα βαρων).
- Κανονικοποίηση βαρών.

Ορισμός κανονικοποίησης βαρών

- 1 Προσθέτουμε έναν ακόμα όρο στο σφάλμα του ΤΝΔ
- 2 Αυτός ο όρος είναι μεγάλος για μεγάλες τιμές των βαρών και μικρός αντίθετα
- 3 Αποφεύγουμε έτσι να δημιουργηθούν μεγάλες τιμές στα βάρη

Κανονικοποίηση

- 1 Θέτουμε

$$V = \sum_{i=1}^n w_i^2$$

- 2 Βάζουμε τετράγωνο για να πάρουμε θετικές τιμές αλλά και γιατί είναι παραγωγίσιμη συνάρτηση
- 3 Για μεγάλες τιμές των βαρών αυτός ο όρος είναι μεγάλος
- 4 Τιμωρούμε τα μεγάλα βάρη

Ενημέρωση βαρών

- 1 Το νέο σφάλμα ορίζεται από τον τύπο

$$E' = \sum_{i=1}^M (N(x_i, w) - y_i)^2 + \lambda V$$

- 2 Προστίθεται ένας ακόμα όρος στην ενημέρωση βαρών
- 3 Ενημέρωση βαρών σύμφωνα με το σχήμα

$$w^{(k+1)} = w^{(k)} + n\Delta w^{(k)} - \lambda w^{(k)}$$

- 1 Η κανονικοποίηση στην παραπάνω μορφή δεν λαμβάνει υπόψη της τα δεδομένα
- 2 Θα δημιουργήσει μικρά βάρη, ακόμα και αν η είσοδος των προτύπων είναι μικρή
- 3 Χρειάζεται πιο γενικός τρόπος κανονικοποίησης.
- 4 Πολύ βασικό: Θα πρέπει οι είσοδοι να έχουν κανονικοποιηθεί σε μικρό διάστημα πχ $[0,1]$ αλλιώς δεν θα βοηθήσει.

Δυναμική Κανονικοποίηση(1)

- 1 Δεν απαιτείται κανονικοποίηση εισόδων
- 2 Λαμβάνεται υπόψη η ιδιαιτερότητα κάθε συνόλου δεδομένων
- 3 Αλλιώς προσαρμόζονται τα βάρη για ένα σύνολο δεδομένων και αλλιώς για άλλο

Δυναμική κανονικοποίηση - σιγμοειδής

- 1 Στα ΤΝΔ χρησιμοποιείται συνήθως η $\sigma(x)$ σαν συνάρτηση ενεργοποίησης
- 2 Η συνάρτηση τείνει πολύ γρήγορα στο 1 καθώς $x \rightarrow \infty$ και πολύ γρήγορα στο 0 καθώς $x \rightarrow -\infty$
- 3 Συνεπώς το νευρωνικό πολύ γρήγορα χάνει τις προσαρμοστικές του δυνατότητες
- 4 Το νευρωνικό ορίζεται:

$$N(\vec{x}, \vec{w}) = \sum_{i=1}^H w_{(d+2)i-(d+1)} \sigma \left(\sum_{j=1}^d x_j w_{(d+2)i-(d+1)+j} + w_{(d+2)i} \right) \quad (1)$$

- 5 Ορίζουμε την συνάρτηση $\mathcal{V}(N(\vec{x}, \vec{w}), F)$, η οποία καταγράφει σε ποσοστό το πλήθος των περιπτώσεων που το όρισμα των σιγμοειδών ξεπερνά ένα παράγοντα F

Η συνάρτηση $\mathcal{V}(N(\vec{x}, \vec{w}), F)$

- 1 **Set** $iv = 0$
- 2 **For** $i = 1..H$ **Do**
 - 1 **For** $j = 1..M$ **Do**
 - 1 **Set** $v = \sum_{k=1}^d w_{(d+2)i-(d+i)+k} x_{jk} + w_{(d+2)i}$
 - 2 **If** $|v| > F$ **set** $iv = iv + 1$
 - 2 **EndFor**
- 3 **EndFor**
- 4 **Return** $\frac{iv}{H \star M}$

problem	sarprop	prune_obs	simple genetic	weight decaying
ion	22.99%	15.46%	18.36%	13.14%
wine	17.45%	30.00%	9.88%	7.19%
fert	19.90%	17.00%	21.10%	14.60%
regions	51.29%	41.37%	32.08%	29.69%
z_f_s	55.43%	29.53%	8.30%	7.00%
z_f_s	50.50%	27.84%	7.44%	5.60%

Πειραματικά αποτελέσματα (μάθηση συναρτήσεων)

problem	sarprop	prune_obs	simple genetic	weight decaying
housing	2810.36	3221.82	1453.91	974.03
bk	2.37	0.52	1.06	0.21
mb	2.08	0.34	0.52	0.27
fa	2.39	1.93	19.394	0.81
nt	3.54	0.21	1.62	0.08

Επαύξηση και κλάδεμα

- Μέθοδοι επαύξησης (growing): πρόσθεση κόμβων σε ένα δίκτυο.
- Μέθοδοι κλαδέματος (pruning): αφαίρεση κόμβων από δίκτυο.

- Ξεκινάμε από M νευρώνες
- Σταδιακά αυξάνουμε τους νευρώνες
- Σταματάμε όταν το σφάλμα ελέγχου πέσει κάτω από ένα όριο ή το σφάλμα στο validation set.

Η μέθοδος Cascade - correlation

- 1 Αρχικά όλες οι εισοδοι ενώνονται με τις εξόδους χωρίς κρυφό στρώμα.
- 2 Γίνεται εκπαίδευση του δικτύου
- 3 Προσθέτουμε ένα νευρώνα στο κρυφό επίπεδο.
- 4 Υπολογίζουμε τα βάρη που συνδέουν τις εισόδους με τον κρυφό νευρώνα
- 5 Παγώνουμε τα βάρη του κρυφού νευρώνα και υπολογίζουμε με εκπαίδευση τα βάρη που συνδέουν τον κρυφό νευρώνα με τις εξόδους καθώς και τα βάρη που ενώνουν τις εισόδους με τις εξόδους
- 6 Μετάβαση στο βήμα 3 μέχρι να ικανοποιηθεί κάποιο κριτήριο τερματισμού, πχ να αρχίσει να ανεβαίνει το σφάλμα στο validation set.

Κλάδεμα βαρών

- Ξεκινάμε με ένα δίκτυο με πολλούς νευρώνες
- Αφού εκπαιδευτεί αποφασίζουμε ποιους κόμβους θα κρατήσουμε
- Για παράδειγμα μπορεί να μειώνεται το μέγεθος του δικτύου μέχρι να διαπιστωθεί αύξηση στο σφάλμα του validation set.

- Προστίθεται στην συνάρτηση σφάλματος ο όρος:

$$\Omega = \frac{1}{2} \sum \left(\frac{w_i^2}{c^2 + w_i^2} \right) \quad (2)$$

- c είναι μια σταθερά που επιλέγει ο χρήστης
- Μετά την εκπαίδευση αφαιρούνται οι νευρώνες με τιμή μικρότερη του c .

Σημαντικότητα βαρών

- Γίνεται εκπαίδευση του δικτύου.
- Για κάθε βάρος w_i υπολογίζεται η ποσότητα

$$S_i = Error(without\ w_i) - Error(with\ w_i)$$

- Αφαιρούμε τα βάρη με σημαντικότητα κάτω από ένα όριο
- Φυσικά απαιτείται αρκετός υπολογιστικός φόρτος.

Το πρόβλημα

Έστω η εξίσωση του νευρωνικού

$$N(\vec{x}, \vec{w}) = \sum_{i=1}^K w_{(d+2)i-(d+1)\sigma} \left(\sum_{j=1}^d x_j w_{(d+2)i-(d+1)+j} + w_{(d+2)i} \right) \quad (3)$$

Αναζητείται μέθοδος υπολογισμού του διαστήματος τιμών για τα βάρη w

Σύγκριση διαστημάτων

Για την σύγκριση δύο διαστημάτων $a = [a_1, a_2]$, $b = [b_1, b_2]$ γίνεται χρήση της συνάρτησης

$$L^*(a, b) = \begin{cases} \text{TRUE}, & a_1 < b_1, \text{ OR } (a_1 = b_1 \text{ AND } a_2 < b_2) \\ \text{FALSE}, & \text{OTHERWISE} \end{cases} \quad (4)$$

Μετατροπή της συνάρτησης σφάλματος σε συνάρτηση διαστημάτων:

$$[E_{min}, E_{max}] = E \left(N \left(\vec{x}, \vec{W} \right) \right) = \sum_{i=1}^M \left(N \left(\vec{x}_i, \vec{W} \right) - y_i \right)^2 \quad (5)$$

Τεχνική δύο σταδίων: Στο πρώτο στάδιο εντοπίζεται ένα διάστημα τιμών για τα βάρη και στο δεύτερο στάδιο εφαρμόζεται ένας γενετικός αλγόριθμος μέσα σε αυτό το διάστημα τιμών.

Η συνάρτηση $B(N(\vec{x}, \vec{w}), F)$

- 1 Set $iv = 0$
- 2 For $i = 1..H$ Do
 - 1 For $j = 1..M$ Do
 - 1 Set $v = \sum_{kT=1}^d w_{(d+2)i-(d+i)+k} x_{jk} + w_{(d+2)i}$
 - 2 If $|v| > F$ set $iv = iv + 1$
 - 2 EndFor
- 3 EndFor
- 4 Return $\frac{iv}{H \star M}$

Ο γενετικός αλγόριθμος

- Χρήση διαστημάτων σαν χρωμοσώματα

- Καταλληλότητα:

Για κάθε χρωμόσωμα g **υπολογισμός** της καταλληλότητας f_g

- 1 Take N_S random samples in g .

- 2 **Calculate** $E_{\min}(g) =$

$$\min_{g_i \in N_S} \left(\left(\sum_{j=1}^M N(x_j, g_i) - y_j \right)^2 + \lambda B^2 (N(x, g), F) \right), \text{ where } \lambda > 0.$$

- 3 **Calculate** $E_{\max}(g) =$

$$\max_{g_i \in N_S} \left(\left(\sum_{j=1}^M N(x_j, g_i) - y_j \right)^2 + \lambda B^2 (N(x, g), F) \right)$$

- 4 **Set** $f_g = [E_{\min}(g), E_{\max}(g)]$.

Εφαρμογή τοπικής βελτίωσης

- ① **Select** randomly L_C chromosomes from the genetic population and create the set L_S from these chromosomes
- ② **For** every chromosome X_i **in** L_S
 - ① **For** $i=1..n$ **Do**
 - ① **Pick** a random position p in chromosome.
 - ② **Set** $Y = X_i$
 - ③ **Set** $Y_p = \left[\text{left}(X_{ip}), \text{left}(X_{ip}) + \frac{(\text{left}(x_{ip}) + \text{right}(x_{ip}))}{2} \right]$
 - ④ **if** $L^*(Y, X_i) = \text{TRUE}$ **then** a) **Set** $X_i = Y$ b) **return**.
 - ⑤ **Set** $Z = X_i$
 - ⑥ **Set** $Z_p = \left[\text{left}(X_{ip}) + \frac{(\text{left}(x_{ip}) + \text{right}(x_{ip}))}{2}, \text{right}(X_{ip}) \right]$
 - ⑦ **if** $L^*(Z, X_i) = \text{TRUE}$ **then** a) **Set** $X_i = Y$ b) **return**.
 - ② **EndFor**

Πειραματικά αποτελέσματα

Dataset	$g = 200$		$g = 500$	
	SIMPLE	PROPOSED	SIMPLE	PROPOSED
WINE	41.55%	9.51%	43.24%	7.59%
GLASS	65.43%	57.76%	67.97%	50.81%
LIVERDISORDER	33.27%	30.07%	31.8%	29.71%
WDBC	10.68%	9.53%	11.10%	8.36%
FERT	22.30%	13.97%	22.17%	13.37%
PARKINSONS	19.86%	17.37%	19.98%	14.65%
TRANSFUSION	25.17%	23.59%	25.36%	23.46%
HAYES ROTH	54.62%	42.72%	54.28%	36.69%
BK	0.32	0.02	1.94	0.02
BL	1.73	0.03	2.61	0.01
FA	0.56	0.01	0.56	0.01
NT	0.71	0.01	0.47	0.01
PY	3.07	0.03	2.50	0.02
ABALONE	5.89	4.50	5.94	4.46

Χρήση κανόνων διαμέρισης

- Έστω η συνάρτηση:

$$f : S \rightarrow R, S \subset R^n, S = [a_1, b_1] \otimes [a_2, b_2] \otimes \dots [a_n, b_n] \quad (6)$$

- Ορισμός του συνόλου I_n :

$$I_n = \{(l_1, r_1), (l_2, r_2), \dots, (l_n, r_n)\} \quad (7)$$

με $l_i \in \{0, 1\}$, $r_i \in \{0, 1\}$, $i = 1, \dots, n$.

- Αν $l_i = 1$ τότε $a_i = \frac{a_i}{2}$ και αν $r_i = 1$ then $b_i = \frac{b_i}{2}$.
- Στην συνέχεια ορίζουμε το σύνολο R_{Kn} σαν σειρά κανόνων διαμέρισης

$$R_{Kn} = \{I_n^{(1)}, I_n^{(2)}, \dots, I_n^{(K)}\} \quad (8)$$

- Για παράδειγμα η συνάρτηση Rastrigin :

$$f(x) = x_1^2 + x_2^2 - \cos(18x_1) - \cos(18x_2), \quad x \in [-1, 1]^2 \quad (9)$$

- Έστω το σύνολο $I_2 = \{(1, 0), (0, 1)\}$ Το παραγόμενο διάστημα τιμών είναι: $S' = [-0.5, 1] \times [-1, 0.5]$.
- Εστω πως $K = 2$ και έστω $R_{22} = \{\{(0, 1), (1, 0)\}, \{(1, 0), (1, 1)\}\}$. Μετά από πράξεις το τελικό διάστημα τιμών θα είναι:
 - 1 **Εφαρμογή** $\{(0, 1), (1, 0)\}$ στο S , $S' = [-0.5, 1] \times [-1, 0.5]$
 - 2 **Εφαρμογή** $\{(1, 0), (1, 1)\}$ στο S' ,
 $S'' = [-0.25, 1] \times [-0.5, 0.25]$

Εφαρμογή κανόνων διαμέρισης σε νευρωνικά δίκτυα

- Δύο φάσεις εκπαίδευσης
- Στην πρώτη φάση με κανόνες εντοπίζεται το βέλτιστο διάστημα τιμών για τα βάρη
- Στην δεύτερη φάση γίνεται ελαχιστοποίηση σε αυτό το διάστημα τιμών
- Η καταλληλότητα είναι παρόμοια όπως και στην προηγούμενη μέθοδο

Πειραματικά αποτελέσματα

DATASET	GENETIC	ADAM	RPROP	NEAT	$D = 200$
Australian	32.21%	35.65%	36.12%	31.98%	28.52%
Balance	8.97%	7.87%	8.81%	23.14%	7.67%
Cleveland	51.60%	67.55%	61.41%	53.44%	44.39%
Dermatology	30.58%	26.14%	15.12%	32.43%	10.80%
Hayes Roth	56.18%	59.70%	37.46%	50.15%	32.05%
Heart	28.34%	38.53%	30.51%	39.27%	16.22%
HouseVotes	6.62%	7.48%	6.04%	10.89%	3.26%
Ionosphere	15.14%	16.64%	13.65%	19.67%	7.12%
Mammographic	19.88%	46.25%	18.46%	22.85%	15.97%
Parkinsons	18.05%	24.06%	22.28%	18.56%	12.53%
Segment	57.72%	49.75%	52.14%	66.72%	40.61%
Wdbc	8.56%	35.35%	21.57%	12.88%	5.49%
Wine	19.20%	29.40%	30.73%	25.43%	6.22%
Z_F_S	10.73%	47.81%	29.28%	38.41%	6.01%
ZO_NF_S	8.41%	47.43%	6.43%	43.75%	5.81%
ZONF_S	2.60%	11.99%	27.27%	5.44%	2.24%
ZOO	16.67%	14.13%	15.47%	20.27%	8.50%

Πειραματικά αποτελέσματα σε μάθηση συναρτήσεων

DATASET	GENETIC	ADAM	RPROP	NEAT	$D = 200$
ABALONE	7.17	4.30	4.55	9.88	3.89
AIRFOIL	0.003	0.005	0.002	0.067	0.003
BASEBALL	103.60	77.90	92.05	100.39	53.57
BK	0.027	0.03	1.599	0.15	0.019
CONCRETE	0.0099	0.078	0.0086	0.081	0.0042
DEE	1.013	0.63	0.608	1.512	0.203
DIABETES	19.86	3.03	1.11	4.25	0.29
HOUSING	43.26	80.20	74.38	56.49	17.75
FA	1.95	0.11	0.14	0.19	0.012
MB	3.39	0.06	0.055	0.061	0.047
MORTGAGE	2.41	9.24	9.19	14.11	0.53
QUAKE	0.040	0.06	0.041	0.298	0.036
TREASURY	2.929	11.16	10.88	15.52	0.622
WANKARA	0.012	0.02	0.0002	0.005	0.0002

Βιβλιογραφία I

-  ITsoulos, I.G., Lagaris, I.E. Solving differential equations with genetic programming. Genet Program Evolvable Mach 7, 33–54 (2006). <https://doi.org/10.1007/s10710-006-7009-y>
-  I. G. Tsoulos, D. Gavrilis and E. Dermatas, GDF: A tool for function estimation through grammatical evolution, Computer Physics Communications 174, pp. 555-559, 2006.
-  I.G. Tsoulos, D. Gavrilis, E. Glavas, “Neural Network Construction and Training using Grammatical Evolution”, Neurocomputing 72, pp. 269-277, 2008.
-  D. Gavrilis, I.G. Tsoulos, E. Dermatas, “Features Selection and Construction using Grammatical Evolution”, Pattern Recognition Letters 29, pp. 1358-1365, 2008.

Βιβλιογραφία II

-  I.G. Tsoulos, D. Gavrilis, E. Glavas, Solving differential equations with constructed neural networks, *Neuromputing* 72, pp. 2385-2391, 2009.
-  Ioannis G. Tsoulos, Creating classification rules using Grammatical Evolution, accepted for publication in *International Journal of Computational Intelligence Studies*, 2018
-  Ioannis G. Tsoulos, Alexandros Tzallas, Dimitrios Tsalikakis, NNC: A tool based on Grammatical Evolution for data classification and differential equation solving, *SoftwareX* 10, 2019.