

Βελτιστοποίηση

Ιωάννης Γ. Τσούλος

Τμήμα Πληροφορικής και τηλεπικοινωνιών
Πανεπιστήμιο Ιωαννίνων

2026

Περίληψη


- 1 Μέθοδοι για μία διάσταση
- 2 Μέθοδοι σε πολλές διαστάσεις

Μέθοδος διχοτόμησης

- Για την ελαχιστοποίηση μιας διαφορίσιμης συνάρτησης $f(x)$ αναζητούμε σημείο x^* τέτοιο ώστε $f'(x^*) = 0$
- **Ξεκινάμε** από διάστημα $[a, b]$ τέτοιο ώστε: $f'(a) < 0$ ή $f'(b) > 0$, δηλαδή η f φθίνει στο a και αυξάνει στο b .
- **Υπολογίζουμε** το μέσο: $c = \frac{a+b}{2}$ και εξετάζουμε το πρόσημο της $f'(c)$
- $f'(c) > 0 \Rightarrow x^* \in [a, c]$
- $f'(c) < 0 \Rightarrow x^* \in [c, b]$
- $f'(c) = 0$, τότε το c είναι στάσιμο σημείο και η αναζήτηση μπορεί να τερματιστεί.

Σχήμα για την μέθοδο διχοτόμησης

Μέθοδος Διχοτόμησης (ελαχιστοποίηση)



Σημείωση: Η μέθοδος απαιτεί αλλαγή προσήμου της παραγώγου στο αρχικό διάστημα $[a, b]$.

Για να εξασφαλίζεται ότι το σημείο που θα βρεθεί είναι το (μοναδικό) ελάχιστο, συνήθως υποθέτουμε ότι η f είναι κυρτή ή μονοτροπική στο $[a, b]$.

Ο αλγόριθμος της μεθόδου διχοτόμησης

- ❶ **Αρχικοποίηση:** Δίνεται διάστημα $[a, b]$ με:
 $f'(a) < 0, f'(b) > 0$. Επιλέγεται $\varepsilon > 0$ και $k = 0$.
- ❷ **Επανάληψη:**
 - ❶ Υπολογίζουμε το μέσο του διαστήματος: $c = \frac{a+b}{2}$ και την παράγωγο $f'(c)$.
 - ❷ Αν $f'(c) > 0, b = c$
 - ❸ Αν $f'(c) < 0, a = c$
 - ❹ Αν $f'(c) = 0$ τερματισμός
- ❸ **Τερματισμός:** Η διαδικασία επαναλαμβάνεται μέχρι $|b - a| \leq \varepsilon$. Η προσεγγιστική λύση είναι $x^* \simeq \frac{a+b}{2}$

Η μέθοδος διχοτόμησης (διάγραμμα ροής)

Ο αλγόριθμος της μεθόδου διχοτόμησης

1. Αρχικοποίηση

- Δίνεται διάστημα $[a, b]$ τέτοιο ώστε $f'(a) < 0$ και $f'(b) > 0$.
- Επιλέγεται ανοχή $\varepsilon > 0$.
- Θέτουμε $k = 0$.

2. Επανάληψη

- Υπολογίζουμε το μέσο του διαστήματος:
$$c = \frac{a+b}{2}$$
- Υπολογίζουμε την παράγωγο $f'(c)$ και ελέγχουμε το πρόσημό της:
 - Αν $f'(c) > 0$, τότε το ελάχιστο βρίσκεται στο $[a, c]$ και θέτουμε $b = c$.
 - Αν $f'(c) < 0$, τότε το ελάχιστο βρίσκεται στο $[c, b]$ και θέτουμε $a = c$.
 - Αν $f'(c) = 0$, τότε το c είναι στάσιμο σημείο και τερματίζουμε.
- Θέτουμε $k = k + 1$.

3. Τερματισμός


- Η διαδικασία επαναλαμβάνεται μέχρι $|b - a| \leq \varepsilon$.
- Ως προσεγγιστική λύση παίρνουμε $x^* \approx \frac{a+b}{2}$.

Πόσες επαναλήψεις;

Μετά από k επαναλήψεις το μήκος του διαστήματος είναι $\frac{b_0 - a_0}{2^k}$.

Για να έχουμε $|b - a| \leq \varepsilon$ αρκεί

$$k \geq \log_2 \left(\frac{b_0 - a_0}{\varepsilon} \right).$$



Σημειώσεις

- Απαιτείται αλλαγή προσημου της παραγώγου στο αρχικό διάστημα $[a, b]$.
- Η μέθοδος συγκλίνει γραμμικά (υποδυναμισμός του διαστήματος).
- Για να είναι το σημείο το (μοναδικό) ελάχιστο, συνήθως υποθέτουμε ότι η f είναι κυρτή ή μονοτροπική στο $[a, b]$.

Παρεμβολή Hermite

- Από τα σημεία a, b διέρχεται ένα μοναδικό πολυώνυμο τρίτου βαθμού:

$$p(x) = c_1x^3 + c_2x^2 + c_3x + c_4$$

- Ισχύει:

$$p(a) = f(a), \quad p'(a) = f'(a), \quad p(b) = f(b), \quad p'(b) = f'(b)$$

- Για την εύρεση των συντελεστών του πολυωνύμου απαιτείται η επίλυση του ακόλουθου γραμμικού συστήματος:

$$c_1a^3 + c_2a^2 + c_3a + c_4 = f(a)$$

$$c_1b^3 + c_2b^2 + c_3b + c_4 = f(b)$$

$$3c_1a^2 + 2c_2a + c_3 = f'(a)$$


$$3c_1b^2 + 2c_2b + c_3 = f'(b)$$

- Μπορεί να επιλυθεί με διάφορες μεθόδους όπως με Gauss.

Παρεμβολή Hermite (σχήμα)

Παρεμβολή Hermite

Το κυβικό πολυώνυμο $p(x)$ έχει την ίδια τιμή και την ίδια κλίση με τη συνάρτηση $f(x)$ στα σημεία a και b .



- Πραγματική συνάρτηση $f(x)$
- - - Κυβική παρεμβολή $p(x)$
- Εφαπτόμενες στα άκρα (κλίσεις)
- Σημεία παρεμβολής


Η παρεμβολή Hermite χρησιμοποιεί τόσο τις τιμές όσο και τις παραγώγους της συνάρτησης στα άκρα, ώστε το $p(x)$ να έχει την ίδια κλίση με την $f(x)$ στα σημεία a και b .

- 1 Στο διάστημα $[a, b]$ γνωρίζουμε: $f(a), f'(a), f(b), f'(b)$
- 2 Κατασκευή του κυβικού πολυώνυμου Hermite $p(x)$ με:
 $p(a) = f(a), p(b) = f(b), p'(a) = f'(a), p'(b) = f'(b)$
- 3 Αντί να αναζητήσουμε απευθείας το ελάχιστο της $f(x)$, χρησιμοποιούμε το $p(x)$ ως τοπικό μοντέλο της συνάρτησης.
- 4 Υπολογισμός: $x^* = \arg \min_{x \in [a, b]} p(x)$ ή ισοδύναμα εύρεση ρίζας της $p'(x)$.

Κυβική παρεμβολή (σχήμα)

Κυβική Παρεμβολή — Μέθοδος Davidon

Χρησιμοποιούμε κυβική παρεμβολή Hermite για να εκτιμήσουμε το ελάχιστο της $f(x)$.



- Πραγματική συνάρτηση $f(x)$
- - - Κυβικό πολυώνυμο $p(x)$ (παρεμβολή Hermite)
- Εφαπτόμενες στα άκρα (ίδιες κλίσεις)
- x^* : ελάχιστο του $p(x)$ (νέο σημείο)
- Σημεία παρεμβολής $(a, f(a))$, $(b, f(b))$

Ιδέα

Το $p(x)$ είναι ένα τοπικό μοντέλο της $f(x)$ που ταιριάζει σε τιμές και παραγώγους στα άκρα. Το ελάχιστό του x^* δίνει μια καλύτερη εκτίμηση του ελαχίστου της $f(x)$ στο διάστημα.

Παρατήρηση: Η μέθοδος Davidon χρησιμοποιεί πληροφορία πρώτης τάξης (παραγώγο) και συνήθως συγκλίνει πιο γρήγορα από τη διχοτόμηση.

1. Κατασκευή κυβικού μοντέλου

Από τα $f(a)$, $f'(a)$, $f(b)$, $f'(b)$ κατασκευάζουμε το κυβικό πολυώνυμο Hermite $p(x)$, που ικανοποιεί

$$\begin{aligned} p(a) &= f(a), & p'(a) &= f'(a) \\ p(b) &= f(b), & p'(b) &= f'(b) \end{aligned}$$

2. Εύρεση ελαχίστου του $p(x)$


Βρίσκουμε το ελάχιστο του $p(x)$ στο $[a, b]$:

$$\begin{aligned} x^* &= \arg \min_{x \in [a, b]} p(x) \\ (\text{ισοδ. } p'(x^*) &= 0) \end{aligned}$$

3. Αξιολόγηση και ενημέρωση

- Υπολογίζουμε την πραγματική τιμή $f(x^*)$.
- Αντικαθιστούμε ένα από τα άκρα a ή b με το x^* (συνήθως το άκρο που δεν περιέχει το ελάχιστο).
- Επαναλαμβάνουμε μέχρι σύγκλιση.

Ροή της μεθόδου



Μέθοδος Davidon (αλγόριθμος)

- 1 **Θέσε** $k = 0$
- 2 **Επανάλαβε**
 - 1 Υπολογισμός πολυωνύμου Hermite $H(a, b)$
 - 2 Εύρεση ελαχίστου

$$x^* = \min_x H(a, b)$$


Η εύρεση του σημείου x^* μπορεί να γίνει και με γραμμική αναζήτηση.

- 3 **Αν** $f(x^*) < f(a)$, $a = x^*$
 - 4 **Αλλιώς** $b = x^*$
 - 5 $k = k + 1$
 - 6 **Αν** $|b - a| \leq \epsilon$, τερματισμός.
- 3 **Τέλος Επανάληψης**

Gradient Descent

- Στην μέθοδο αυτή γίνεται αναζήτηση του ελαχίστου κατά μήκους της $-\nabla f(x)$
- Η μέθοδος είναι γνωστή και με το όνομα Back Propagation όταν εφαρμόζεται στην ελαχιστοποίηση σφαλμάτων σε Τεχνητά νευρωνικά δίκτυα.
- Αποτελεί την βάση για πιο σύνθετες και πιο αποδοτικές τεχνικές βελτιστοποίησης.
- Βασίζεται πολύ στο βήμα h που θα επιλεγεί.
- Περιπτώσεις:
 - h πολύ μικρό $\Rightarrow$ Αργή σύγκλιση
 - h κατάλληλο $\Rightarrow$ σταθερή σύγκλιση
 - h πολύ μεγάλο $\Rightarrow$ ταλαντώσεις ή απόκλιση

Gradient Descent — Μέθοδος Κατιούσας Κλίσης



Βασική ιδέα

Ξεκινώντας από ένα αρχικό σημείο x_0 , κινούμαστε επαναληπτικά στην κατεύθυνση $-\nabla f(x_k)$, οπότε η τιμή της συνάρτησης μειώνεται και η ακολουθία $\{x_k\}$ συγκλίνει (υπό κατάλληλες συνθήκες) σε ένα ελάχιστο x^* .

Ενημέρωση της λύσης

$$x_{k+1} = x_k - h \nabla f(x_k)$$

όπου $h > 0$ είναι το μέγεθος βήματος (step size / learning rate).

Ιδιότητες

- Η $\nabla f(x)$ δείχνει την κατεύθυνση της μεγαλύτερης τοπικής αύξησης της f .
- Η $-\nabla f(x)$ είναι η κατεύθυνση της μεγαλύτερης τοπικής μείωσης.
- Η μέθοδος παράγει μια ακολουθία σημείων $x_0, x_1, x_2, \dots$ που πλησιάζει το (τοπικό) ελάχιστο x^* .

Ρόλος του βήματος h

- h πολύ μικρό $\Rightarrow$ αργή σύγκλιση
- h κατάλληλο $\Rightarrow$ σταθερή σύγκλιση
- h πολύ μεγάλο $\Rightarrow$ ταλαντώσεις ή απόκλιση

Σημείωση

Ο αλγόριθμος Gradient Descent χρησιμοποιείται ευρέως για την εκπαίδευση νευρωνικών δικτύων. Το backpropagation είναι η διαδικασία υπολογισμού των gradients, ενώ ο Gradient Descent είναι ο αλγόριθμος ενημέρωσης των παραμέτρων.

Ο αλγόριθμος Gradient Descent

- 1 **Αρχικοποίηση:** Επιλογή x_0 , $h > 0$, $k = 0$
- 2 **Υπολογισμός κλίσης:** $g_k = \nabla f(x_k)$
- 3 **Ενημέρωση λύσης:** $x_{k+1} = x_k - hg_k$
- 4 **Ενημέρωση επανάληψης:** $k = k + 1$
- 5 **Τερματισμός:** Μέχρι να ικανοποιηθεί το κριτήριο τερματισμού επανάληψη από 2.

Ο αλγόριθμος Gradient Descent(διάγραμμα ροής)

Αλγόριθμος Gradient Descent

1. Αρχικοποίηση

- Επιλέγουμε αρχικό σημείο $x_0 \in \mathbb{R}^n$.
- Επιλέγουμε μέγεθος βήματος $h > 0$.
- Θέτουμε $k = 0$.

2. Υπολογισμός κλίσης

- Υπολογίζουμε το διάνυσμα κλίσης στο τρέχον σημείο:

$$g_k = \nabla f(x_k)$$

3. Ενημέρωση λύσης

- Μετακινούμαστε προς την κατεύθυνση της αρνητικής κλίσης:

$$x_{k+1} = x_k - hg_k = x_k - h \nabla f(x_k)$$

4. Ενημέρωση επανάληψης

- Θέτουμε $k \leftarrow k + 1$.

5. Κριτήριο τερματισμού


- Επαναλαμβάνουμε τα βήματα 2-4 μέχρι να ικανοποιηθεί κάποιο κριτήριο τερματισμού, π.χ.

$$\|\nabla f(x_k)\| \leq \varepsilon \quad \text{ή} \quad k \geq k_{\max}$$

Βασική ιδέα

Σε κάθε βήμα κινούμαστε από το x_k προς την κατεύθυνση $-\nabla f(x_k)$, οπότε η τιμή της συνάρτησης μειώνεται (για κατάλληλο h) και η ακολουθία $\{x_k\}$ συγκλίνει σε ένα (τοπικό) ελάχιστο x^* .

Διάγραμμα ροής του αλγορίθμου



Ακολουθία επαναλήψεων



Κριτήρια τερματισμού

- ❶ Μικρή κλίση: $\nabla f(x_k) \leq \epsilon$
- ❷ Μικρή μεταβολή της λύσης: $\|x_{k+1} - x_k\| \leq \epsilon$
- ❸ Μικρή μεταβολή της αντικειμενικής συνάρτησης:
 $|f(x_{k+1}) - f(x_k)| \leq \epsilon$
- ❹ Μέγιστος αριθμός επαναλήψεων. $k \geq k_{max}$ Χρησιμοποιείται ως δικλείδα ασφαλείας, ώστε ο αλγόριθμος να μην εκτελείται επ' αόριστον.

Υπολογισμός h

- Η ενημέρωση του Gradient Descent είναι:

$$x_{k+1} = x_k - h \nabla f(x_k)$$

όπου $h > 0$ καθορίζει πόσο μακριά κινούμαστε στην κατεύθυνση της αρνητικής κλίσης.


- Μπορεί να τεθεί σε πολύ χαμηλή τιμή (αργή σύγκλιση).
- Μπορεί να ξεκινάει από υψηλές τιμές και να μειώνεται (όπως η θερμοκρασία στο Simulated Annealing).
- Μπορεί να υπολογιστεί με ελαχιστοποίηση της συνάρτησης $\phi(h) = f(x_k - h \nabla f(x_k))$ (γραμμική αναζήτηση).
- Θέλει προσοχή ο υπολογισμός καθώς μπορεί να δημιουργηθούν και σημεία **εκτός πεδίου ορισμού** της συνάρτησης.

Υπολογισμός βήματος

Επιλογή μεγέθους βήματος h στον Gradient Descent

Πολύ μικρό βήμα ($h = 0.05$)


Αργή σύγκλιση (πολλές επαναλήψεις)



- Μικρές μετακινήσεις σε κάθε επανάληψη.
- Σταθερή αλλά αργή σύγκλιση.
- Απαιτούνται πολλές επαναλήψεις.

Κατάλληλο βήμα ($h = 0.5$)


Γρήγορη και σταθερή σύγκλιση



- Επαρκώς μεγάλο βήμα.
- Γρήγορη και σταθερή σύγκλιση.
- Καλή ισορροπία μεταξύ ταχύτητας και σταθερότητας.

Πολύ μεγάλο βήμα ($h = 1.5$)

Ταλαντώσεις ή απόκλιση



- Πολύ μεγάλες μετακινήσεις.
- Η μέθοδος προσπερνά το ελάχιστο.
- Προκαλεί ταλαντώσεις ή ακόμη και απόκλιση.

Σύγκριση συμπεριφοράς

h μικρό	⇒	αργή σύγκλιση (πολλές επαναλήψεις)
h κατάλληλο	⇒	γρήγορη και σταθερή σύγκλιση
h μεγάλο	⇒	ταλαντώσεις / απόκλιση

Γραμμική αναζήτηση (Line Search)

Αντί για σταθερό h , μπορούμε σε κάθε επανάληψη να επιλέγουμε:

$$h_k = \arg \min_{h>0} f(x_k - h \nabla f(x_k))$$

και στη συνέχεια:

$$x_{k+1} = x_k - h_k \nabla f(x_k)$$

Χρήση Momentum στην μέθοδο Gradient Descent

- Στον απλό Gradient Descent:

$$x_{k+1} = x_k - h \nabla f(x_k)$$

η νέα κατεύθυνση εξαρτάται μόνο από την τρέχουσα κλίση.

- Στο Momentum διατηρούμε πληροφορία από τις προηγούμενες κινήσεις:

$$v_{k+1} = \beta v_k - h \nabla f(x_k)$$

και ενημερώνουμε τη λύση $x_{k+1} = x_k + v_{k+1}$ με β να είναι ο συντελεστής ορμής (momentum coefficient).

- Τι κάνει το Momentum: Ο όρος βv_k διατηρεί μέρος της προηγούμενης κίνησης, ενώ ο όρος

$$-h \nabla f(x_k)$$


προσθέτει την πληροφορία της τρέχουσας κλίσης.

Η μέθοδος Momentum Gradient Descent

Gradient Descent με Momentum — Σύγκριση συμπεριφοράς

Απλός Gradient Descent

Έντονες ταλαντώσεις (zig-zag) σε στενή κοιλάδα




Απλός Gradient Descent

$$x_{k+1} = x_k - h \nabla f(x_k)$$

- Η νέα κατεύθυνση εξαρτάται μόνο από την τρέχουσα κλίση.
- Σε στενές κοιλάδες εμφανίζει zig-zag συμπεριφορά.
- Απαιτούνται περισσότερες επαναλήψεις.

Gradient Descent με Momentum

Πιο ομαλή πορεία και ταχύτερη σύγκλιση



Gradient Descent με Momentum

$$v_{k+1} = \beta v_k - h \nabla f(x_k)$$

$$x_{k+1} = x_k + v_{k+1}$$

- Ο όρος βv_k διατηρεί μέρος της προηγούμενης κίνησης.
- Εξομαλύνει τις ταλαντώσεις.
- Δίνει ταχύτερη πρόοδο προς το ελάχιστο.
- Συχνά χρησιμοποιείται $\beta = 0.9$.

Παράμετρος Momentum

$$0 \leq \beta < 1$$

β : συντελεστής ορμής
(momentum coefficient)

- $\beta = 0 \Rightarrow$ απλός Gradient Descent
- Όσο μεγαλύτερο το β , τόσο μεγαλύτερη η επίδραση της προηγούμενης κίνησης.
- Στην πράξη: $\beta = 0.9$.

Συμπέρασμα

Το Momentum βοηθά τη μέθοδο να διατηρεί την κατεύθυνση της κίνησης, μειώνει τις ταλαντώσεις και οδηγεί συνήθως σε ταχύτερη σύγκλιση, ιδιαίτερα σε προβλήματα με επιμήκεις κοιλάδες.


Η μέθοδος ADAM

- Η ADAM συνδυάζει την ιδέα του Momentum με προσαρμοζόμενο μέγεθος βήματος για κάθε παράμετρο.
- Σε κάθε επανάληψη υπολογίζουμε: $g_k = \nabla f(x_k)$ και διατηρούμε δύο εκθετικούς κινητούς μέσους.
 - **Πρώτη ροπή** — Momentum $m_k = \beta_1 m_{k-1} + (1 - \beta_1) g_k$. Το m_k αποτελεί εξομαλυσμένη εκτίμηση της κατεύθυνσης της κλίσης.
 - **Δεύτερη ροπή** $u_k = \beta_2 u_{k-1} + (1 - \beta_2) g_k^2$ όπου το g_k^2 υπολογίζεται ανά συνιστώσα. Το u_k περιέχει πληροφορία για το μέγεθος των πρόσφατων gradients.
- **Διόρθωση αρχικής μεροληψίας**: Αρχικοποιούμε $m_0 = 0, \quad u_0 = 0$ και ενημερώνουμε:
$$\widetilde{m}_k = \frac{m_k}{1 - \beta_1^k}, \quad \widetilde{u}_k = \frac{u_k}{1 - \beta_2^k}$$
- **Ενημέρωση σημείου**: $x_{k+1} = x_k - h \frac{\widetilde{m}_k}{\sqrt{\widetilde{u}_k + \epsilon}}$
- Τυπικές τιμές παραμέτρων: $\beta_1 = 0.9 \quad \beta_2 = 0.999 \quad \epsilon = 10^{-8}$

Η μέθοδος Adam (σχήμα)

ADAM — Adaptive Moment Estimation

Διάγραμμα ροής και βασικά βήματα



1. Πρώτη ροπή (Momentum) $m_k = \beta_1 m_{k-1} + (1 - \beta_1) g_k$ - Εξομαλύνει τις ταλαντώσεις. - Διατηρεί πληροφορία από προηγούμενες κινήσεις. - Παίζει ρόλο κατεύθυνσης.	2. Δεύτερη ροπή $u_k = \beta_2 u_{k-1} + (1 - \beta_2) g_k^2$ - Καταγράφει το μέγεθος των πρόσφατων gradients. - Χρησιμοποιείται για προσαρμογή του βήματος ανά συνιστώσα. - Το g_k^2 υπολογίζεται ανά συνιστώσα (element-wise).	3. Διόρθωση μεροληψίας $\hat{m}_k = \frac{m_k}{1 - \beta_1^k}$ $\hat{u}_k = \frac{u_k}{1 - \beta_2^k}$ Απαραίτητη επειδή ξεκινάμε με $m_0 = 0$, $u_0 = 0$.	4. Ενημέρωση $x_{k+1} = x_k - h \frac{\hat{m}_k}{\sqrt{\hat{u}_k} + \epsilon}$ - Συνδυάζει κατεύθυνση ($\hat{m}_k$) και κλίμακα ($\hat{u}_k$). - Προσαρμοζόμενο μέγεθος βήματος για κάθε παράμετρο. - Το ϵ αποτρέπει διαίρεση με το μηδέν.
Τυπικές τιμές παραμέτρων $\beta_1 = 0.9 \quad \beta_2 = 0.999 \quad \epsilon \approx 10^{-8}$ Λειτουργεί καλά σε πολλά προβλήματα.	Συνολική ιδέα Το ADAM συνδυάζει: - την ιδέα του Momentum (πρώτη ροπή) - την προσαρμογή του βήματος (δεύτερη ροπή) - και τη διόρθωση μεροληψίας, ώστε να επιτυγχάνει ταχύτερη και πιο σταθερή σύγκλιση.	Σύγκριση ενημέρωσης Απλός Gradient Descent: $x_{k+1} = x_k - h g_k$ (ίδιο βήμα για όλες τις συνιστώσες) ADAM: $x_{k+1} = x_k - h \frac{\hat{m}_k}{\sqrt{\hat{u}_k} + \epsilon}$ (διαφορετικό αποτελεσματικό βήμα για κάθε συνιστώσα)	

Ο αλγόριθμος της μεθόδου ADAM (παράμετροι)

- Μέγεθος βήματος $\alpha > 0$, τυπική τιμή $\alpha = 0.001$
- Παράμετρος β_1 , Καθορίζει πόση πληροφορία διατηρείται από τον κινητό μέσο της κλίσης m_k . Τυπική τιμή $\beta_1 = 0.9$
- Παράμετρος β_2 , Καθορίζει πόση πληροφορία διατηρείται από τον κινητό μέσο του τετραγώνου της κλίσης u_k . Τυπική τιμή $\beta_2 = 0.999$

Ο αλγόριθμος ADAM (βήματα)

- ❶ **Θέσε** $m_0 = 0$, πρώτο διάνυσμα momentum
- ❷ **Θέσε** $u_0 = 0$, δεύτερο διάνυσμα momentum
- ❸ **Θέσε** $k = 0$, αριθμός επαναλήψεων
- ❹ **Έστω** ένα νέο δείγμα από την συνάρτηση x_0
- ❺ **Μέχρι** τερματισμό **κάνε**
 - ❶ $g_k = \nabla f(x_k)$
 - ❷ $m_{k+1} = \beta_1 m_k + (1 - \beta_1) g_k$
 - ❸ $u_{k+1} = \beta_2 u_k + (1 - \beta_2) g_k^2$
 - ❹ $\hat{m}_{k+1} = \frac{1}{1 - \beta_1^{k+1}} m_{k+1}$, παίρνει δυνάμεις για τα β_1, β_2 ώστε να μειώνεται η επίδρασή τους όσο περνάνε οι επαναλήψεις.
 - ❺ $\hat{u}_{k+1} = \frac{1}{1 - \beta_2^{k+1}} u_{k+1}$
 - ❻ $x_{k+1} = x_k - \alpha \frac{\hat{m}_{k+1}}{(\sqrt{\hat{u}_{k+1}} + \epsilon)}$
 - ❼ $k = k + 1$
- ❻ **Τέλος - Μέχρι**

Παραλλαγές μεθόδου ADAM και Gradient Descent

- AdaGrad
- AdaDelta
- AdaMax
- AMSGrad
- RMSProp
- NADam

Η μέθοδος AMSGRAD

- Η AMSGrad αλλάζει την δεύτερη ροπή στην Adam.
- Στον ADAM υπολογίζουμε: $u_k = \beta_2 u_{k-1} + (1 - \beta_2) g_k^2$
- Η AMSGrad διατηρεί επιπλέον τη μέγιστη τιμή που έχει εμφανιστεί μέχρι την τρέχουσα επανάληψη, ανά συνιστώσα: $\widetilde{u}_k = \max(\widetilde{u}_{k-1}, u_k)$ με $u_0 = 0$.
- Η ενημέρωση πραγματοποιείται χρησιμοποιώντας το $\widetilde{u}_k$:
$$x_{k+1} = x_k - \alpha \frac{\widehat{m}_k}{\sqrt{\widetilde{u}_k + \epsilon}}$$
- **Ποια είναι η βασική διαφορά** $\Rightarrow$ ADAM: η ποσότητα u_k μπορεί να αυξάνεται ή να μειώνεται ενώ στην AMSGrad:

$$\widetilde{u}_k \geq \widetilde{u}_{k-1}$$

δηλαδή η ποσότητα που χρησιμοποιείται για την κλιμάκωση του βήματος δεν μειώνεται.

- Έτσι αποφεύγονται ορισμένες προβληματικές συμπεριφορές του προσαρμοζόμενου βήματος.

AMSGRAD (σχηματικά)

AMSGrad — Μια παραλλαγή του ADAM

Βασική ιδέα

Η AMSGrad είναι παραλλαγή του ADAM που τροποποιεί τον τρόπο με τον οποίο χρησιμοποιείται η δεύτερη ροπή, διατηρώντας τη μέγιστη τιμή της μέχρι την τρέχουσα επανάληψη.

1. Υπολογισμός ροπών (όπως στον ADAM)

$$m_k = \beta_1 m_{k-1} + (1 - \beta_1) g_k$$

(1η ροπή — momentum)

$$u_k = \beta_2 u_{k-1} + (1 - \beta_2) g_k^2$$

(2η ροπή — ανά συνιστώσα)

2. Τροποποίηση δεύτερης ροπής

$$\tilde{u}_k = \max(\tilde{u}_{k-1}, u_k)$$

$$\tilde{u}_0 = 0$$

- Διατηρούμε τη μέγιστη τιμή που έχει εμφανιστεί μέχρι την τρέχουσα επανάληψη.
- Ισχύει: $\tilde{u}_k \geq \tilde{u}_{k-1}$ (ανά συνιστώσα).

3. Διόρθωση μεροληψίας (όπως στον ADAM)

$$\hat{m}_k = \frac{m_k}{1 - \beta_1^k}, \quad \hat{u}_k = \frac{\tilde{u}_k}{1 - \beta_2^k}$$

4. Ενημέρωση παραμέτρων


$$x_{k+1} = x_k - \alpha \frac{\hat{m}_k}{\sqrt{\hat{u}_k} + \epsilon}$$

(ανά συνιστώσα)


5. Υπόλοιπα βήματα

- $k \leftarrow k + 1$
- Επανάληψη μέχρι να ικανοποιηθεί το κριτήριο τερματισμού.

Συμπεριφορά της δεύτερης ροπής στον ADAM



Συμπεριφορά της δεύτερης ροπής στην AMSGrad



Συμπέρασμα

Η AMSGrad χρησιμοποιεί $\tilde{u}_k = \max(\tilde{u}_{k-1}, u_k)$ ώστε η ποσότητα που κλιμακώνει το βήμα να μην μειώνεται. Αυτό αποφεύγει ορισμένες προβληματικές συμπεριφορές του ADAM και παρέχει ισχυρότερες θεωρητικές ιδιότητες σύγκλισης σε συγκεκριμένες περιπτώσεις.

Από το Gradient Descent στην BFGS

- Στο Gradient Descent: $x_{k+1} = x_k - \alpha_k \nabla f(x_k)$
χρησιμοποιούμε μόνο την πληροφορία της κλίσης.
- Η μέθοδος Newton χρησιμοποιεί επιπλέον την
καμπυλότητα: $x_{k+1} = x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k)$ με τον
πίνακα $\nabla^2 f(x_k)$ να αναπαριστά τον Εσσιανό πίνακα.
- Το πρόβλημα είναι ότι ο υπολογισμός και ιδιαίτερα η
επίλυση συστήματος με τον Hessian μπορεί να είναι ακριβός.

- 1 Η BFGS (Broyden–Fletcher–Goldfarb–Shanno) είναι μέθοδος Quasi-Newton.
- 2 Δεν υπολογίζει τον Hessian σε κάθε επανάληψη. Αντί γι' αυτό κατασκευάζει σταδιακά μια προσέγγιση H_k του αντίστροφου Hessian: $H_k \simeq [\nabla^2 f(x_k)]$
- 3 Η κατεύθυνση υπολογίζεται ως: $p_k = -H_k \nabla f(x_k)$
- 4 Η ενημέρωση γίνεται: $x_{k+1} = x_k + a_k p_k$

Ενημέρωση στην BFGS

- 1 Έστω ότι μετά από μία επανάληψη έχουμε μετακινηθεί:
 $x_k \rightarrow x_{k+1}$
- 2 Ορίζουμε την μεταβολή της θέσης: $s_k = x_{k+1} - x_k$
- 3 Ορίζουμε την μεταβολή της κλίσης:
 $y_k = \nabla f(x_{k+1}) - \nabla f(x_k)$ και τον όρο $\rho_k = \frac{1}{y_k^T s_k}$
- 4 Η BFGS ενημερώνει την προσέγγιση H_k του αντίστροφου Hessian σύμφωνα με:

$$H_{k+1} = \left(I - \rho_k s_k y_k^T\right) H_k \left(I - \rho_k y_k s_k^T\right) + \rho_k s_k s_k^T$$

- 5 **Σημαντική συνθήκη:** Θα πρέπει πάντα το γινόμενο $y_k^T s_k > 0$. Με αυτή τη συνθήκη, αν το H_k είναι θετικά ορισμένο, η ενημέρωση BFGS διατηρεί τη θετική οριστικότητα. Έτσι η κατεύθυνση $-H_k \nabla f(x_k)$ παραμένει φθίνουσα κατεύθυνση.

BFGS (σχηματικά)

BFGS — Ενημέρωση του αντίστροφου Hessian

1. Διαφορές θέσης και κλίσης

Μετά από μία επανάληψη, ορίζουμε:

$$s_k = x_{k+1} - x_k \quad (\text{μεταβολή θέσης})$$

$$y_k = \nabla f(x_{k+1}) - \nabla f(x_k) \quad (\text{μεταβολή κλίσης})$$

2. Παράμετρος ρ_k

$$\rho_k = \frac{1}{y_k^T s_k}$$

3. Ενημέρωση BFGS

Η προσέγγιση H_k του αντίστροφου Hessian ενημερώνεται με:

$$H_{k+1} = (I - \rho_k s_k y_k^T) H_k (I - \rho_k y_k s_k^T) + \rho_k s_k s_k^T$$

4. Νέα κατεύθυνση και επόμενο βήμα

$$p_{k+1} = -H_{k+1} \nabla f(x_{k+1})$$


$$x_{k+2} = x_{k+1} + \alpha_{k+1} p_{k+1}$$

5. Σημαντική συνθήκη


$$y_k^T s_k > 0$$

Αν H_k είναι θετικά ορισμένο και ισχύει $y_k^T s_k > 0$, τότε το H_{k+1} παραμένει θετικά ορισμένο και η κατεύθυνση $-H_k \nabla f(x_k)$ είναι κατεύθυνση καθόδου.

Γεωμετρική ερμηνεία των s_k και y_k



Σχηματική ροή της ενημέρωσης



Συμπέρασμα

Η BFGS χρησιμοποιεί πληροφορία από διαδοχικά σημεία και κλίσεις, ώστε να κατασκευάσει μια ολοένα καλύτερη προσέγγιση του αντίστροφου Hessian, χωρίς να υπολογίζει ρητά τον Hessian.

Σύνοψη

- Μέθοδοι με παραγώγους στην μία διάσταση
- Μέθοδοι με παραγώγους σε πολλές διαστάσεις