

Βελτιστοποίηση

Ιωάννης Γ. Τσούλος

Τμήμα Πληροφορικής και τηλεπικοινωνιών
Πανεπιστήμιο Ιωαννίνων

2026

Περίληψη

- 1 Η μέθοδος Newton για ελαχιστοποίηση
- 2 Η μέθοδος Levenberg Marquardt
- 3 Παραδείγματα προβλημάτων

Μέθοδος Newton σε μία διάσταση

- 1 Για την ελαχιστοποίηση μιας διαφορίσιμης συνάρτησης:
 $\min_x f(x)$ αναζητούμε στάσιμο σημείο x^* ώστε $f'(x^*) = 0$.
- 2 Εφαρμόζοντας τη μέθοδο Newton στην εξίσωση $f'(x) = 0$ προκύπτει

$$x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)}$$

- 3 **Γεωμετρική ερμηνεία:** Κοντά στο x_k η συνάρτηση f προσεγγίζεται

$$f(x_k + s) \simeq f(x_k) + f'(x_k)s + \frac{1}{2}f''(x_k)s^2$$


με ελαχιστοποίηση ως προς s προκύπτει:

$$f'(x_k) + f''(x_k)s = 0, \text{ οπότε: } s_k = -\frac{f'(x_k)}{f''(x_k)}$$

- 4 Βασική απαίτηση $f''(x) > 0$, δηλαδή για κυρτές συναρτήσεις.

Σχήμα για την μονοδιάστατη Newton

Μέθοδος Newton σε μία διάσταση – Γεωμετρική ερμηνεία



Συμπέρασμα

$$f'(x^*) = 0 \Rightarrow x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)}$$

(Η μέθοδος Newton εφαρμόζεται στη συνάρτηση $f'(x)$.)

Ιδέα

Για την ελαχιστοποίηση μιας διαφορίσιμης συνάρτησης $f(x)$ αναζητούμε στάσιμο σημείο:

$$f'(x^*) = 0$$

Βήμα Newton

Εφαρμόζοντας τη μέθοδο Newton στην εξίσωση $f'(x) = 0$, προκύπτει:

$$x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)}$$

Τετραγωνική προσέγγιση

Κονιά στο x_k προσεγγίζουμε τη f με:

$$f(x_k + s) \approx f(x_k) + f'(x_k)s + \frac{1}{2}f''(x_k)s^2$$

Ελαχιστοποιώντας ως προς s :

$$f'(x_k) + f''(x_k)s = 0 \Rightarrow s_k = -\frac{f'(x_k)}{f''(x_k)}$$

και $x_{k+1} = x_k + s_k$.

Προϋπόθεση

Αν $f''(x_k) > 0$ (τοπική κυρτότητα), τότε το τετραγωνικό μοντέλο έχει ελάχιστο και το βήμα κατευθύνεται προς ελάχιστο.

Παράδειγμα σε μία διάσταση

- ❶ Έστω η συνάρτηση

$$f(x) = \frac{x^2}{2} - 0.8x + 0.2 \cos(x)$$

- ❷ Η δεύτερη παράγωγος είναι

$$f''(x) = 1 - 0.2 \cos(x)$$

και είναι μονίμως θετική. Άρα η f είναι αυστηρά κυρτή και διαθέτει μοναδικό συνολικό ελάχιστο.

- ❸ Γίνονται τα ακόλουθα βήματα

ITER	$f(x)$
1	0.05766426794
2	-0.1913444931
3	-0.1925042934
4	-0.1925043213

Το παράδειγμα γραφικά

Παράδειγμα Newton σε μία διάσταση

Συνάρτηση

$$f(x) = \frac{x^2}{2} - 0.8x + 0.2 \cos(x)$$

Παράγωγοι

$$f'(x) = x - 0.8 - 0.2 \sin(x)$$

$$f''(x) = 1 - 0.2 \cos(x)$$


Κυρτότητα

$$-1 \leq \cos(x) \leq 1 \Rightarrow 0.8 \leq f''(x) \leq 1.2$$

$$f''(x) > 0, \quad \forall x$$

Η f είναι αυστηρά κυρτή και έχει μοναδικό ελάχιστο.

Γραφική παράσταση της συνάρτησης και τα βήματα της Newton



Τύπος επανάληψης Newton

$$x_{k+1} = x_k - \frac{x_k - 0.8 - 0.2 \sin(x_k)}{1 - 0.2 \cos(x_k)}$$

Αποτελέσματα (αρχικό σημείο $x_0 = 3$)

k	x_k	$f'(x_k)$	$f(x_k)$
0	3.0000000000	2.1716800121	0.5570037526
1	1.3242762510	0.3951893047	-0.1344602550
2	0.8423380713	0.0273564689	-0.1913444931
3	0.8057087269	0.0002715672	-0.1925042934
4	0.8053443124	0.0000000289	-0.1925043213

Συμπέρασμα

- Η μέθοδος συγκλίνει πολύ γρήγορα (σε 3-4 επαναλήψεις).
- Το ελάχιστο είναι $x^* \approx 0.805344$ με τιμή $f(x^*) \approx -0.192504$.
- Η θετική δεύτερη παράγωγος εξασφαλίζει μοναδικό ελάχιστο.

Μέθοδος Newton σε πολλές διαστάσεις

- 1 **Θέσε** $k = 0$
- 2 **Αρχικοποίηση** x_0
- 3 **Όσο** δεν ικανοποιούνται τα κριτήρια τερματισμού
 - 1 **Επίλυση** του συστήματος $H_f(x_k) \Delta x_k = \nabla f(x_k)$, χρήση Εσσιανού πίνακα
 - 2 **Θέσε** $x_{k+1} = x_k - \Delta x_k$
 - 3 $k = k + 1$
- 4 **Τέλος Επανάληψης**

Διάγραμμα για την πολυδιάστατη Newton

Μέθοδος Newton σε πολλές διαστάσεις

Ελαχιστοποίηση μη γραμμικών συναρτήσεων

Πρόβλημα

Ελαχιστοποίηση μιας διαφορίσιμης συνάρτησης $f: \mathbb{R}^n \rightarrow \mathbb{R}$

$$\min_{x \in \mathbb{R}^n} f(x)$$

Ιδέα

Κοντά στο τρέχον σημείο x_k προσεγγίζουμε τη συνάρτηση με το δεύτερης τάξης (τετραγωνικό) μοντέλο

$$f(x_k + s) \approx f(x_k) + g_k^T s + \frac{1}{2} s^T H_k s$$

όπου $g_k = \nabla f(x_k)$ και $H_k = \nabla^2 f(x_k)$.

Το ελάχιστο του μοντέλου δίνει $H_k s = -g_k$.

Επαναληπτικός αλγόριθμος


- 1 Αρχικοποίηση: x_0 και $k = 0$
- 2 Υπολογισμός κλίσης και Εσσιανού: $g_k = \nabla f(x_k)$, $H_k = \nabla^2 f(x_k)$
- 3 Επίλυση γραμμικού συστήματος: $H_k \Delta x_k = -g_k$
- 4 Ενημέρωση: $x_{k+1} = x_k + \Delta x_k$
- 5 $k = k + 1$ και επανάληψη μέχρι να ικανοποιηθούν τα κριτήρια τερματισμού.

Ισοδύναμη μορφή (αν ο H_k είναι αντιστρέψιμος)

$$x_{k+1} = x_k - H_k^{-1} \nabla f(x_k)$$


Στην πράξη προτιμάμε την επίλυση του συστήματος $H_k \Delta x_k = -g_k$ και όχι τον υπολογισμό του H_k^{-1} .

Γεωμετρική ερμηνεία



Τα σημεία x_k που παράγονται από τη μέθοδο Newton προσεγγίζουν γρήγορα το ελάχιστο x^* .

Διάγραμμα ροής του αλγορίθμου



Κριτήρια τερματισμού (ενδεικτικά)

- $\|\nabla f(x_k)\| \leq \epsilon_g$
- $\|\Delta x_k\| \leq \epsilon_x$
- $|f(x_{k+1}) - f(x_k)| \leq \epsilon_f$
- Μέγιστος αριθμός επαναλήψεων.

Παρατηρήσεις

- Αν ο H_k είναι θετικά ορισμένος, το βήμα είναι κατεύθυνση καθόδου.
- Η μέθοδος έχει τετραγωνική σύγκλιση κοντά στο ελάχιστο.
- Απαιτεί υπολογισμό/προσέγγιση του Εσσιανού.

Παράδειγμα εφαρμογής σε δύο διαστάσεις

- ❶ Έστω η συνάρτηση

$$f(x) = 2x_1^2 + 3x_1x_2 - 5x_1 + 4x_2^2 + 2x_2$$


- ❷ Η κλίση είναι: $\nabla f(x) = [4x_1 + 3x_2 - 5, 3x_1 + 8x_2 + 2]$
- ❸ Ο Εσσιανός πίνακας δίνεται από την εξίσωση

$$H_f = \begin{bmatrix} 4 & 3 \\ 3 & 8 \end{bmatrix}$$

- ❹ Αν θέσουμε $x_0 = (1, 0)$, η παράγωγος είναι το διάνυσμα $[-1, 5]$ και το νέο σημείο είναι το $x_1 = (2, -1)$ το οποίο είναι και τοπικό ελάχιστο.

Σχήμα για το προηγούμενο παράδειγμα

Παράδειγμα Newton σε δύο διαστάσεις



Συνάρτηση

$$f(x_1, x_2) = 2x_1^2 + 3x_1x_2 - 5x_1 + 4x_2^2 + 2x_2$$

Κλίση και Εσσιανός

$$\nabla f(x_1, x_2) = \begin{bmatrix} 4x_1 + 3x_2 - 5 \\ 3x_1 + 8x_2 + 2 \end{bmatrix} \quad H_f = \begin{bmatrix} 4 & 3 \\ 3 & 8 \end{bmatrix}$$

Ένα βήμα Newton

$$\text{Αρχικό σημείο: } x_0 = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \quad \nabla f(x_0) = \begin{bmatrix} -1 \\ 5 \end{bmatrix}$$

$$\text{Λύνουμε: } H_f \Delta x_0 = -\nabla f(x_0) \Rightarrow \begin{bmatrix} 4 & 3 \\ 3 & 8 \end{bmatrix} \Delta x_0 = \begin{bmatrix} 1 \\ -5 \end{bmatrix}$$

$$\Delta x_0 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

$$\text{Νέο σημείο: } x_1 = x_0 + \Delta x_0 = \begin{bmatrix} 1 \\ 0 \end{bmatrix} + \begin{bmatrix} 1 \\ -1 \end{bmatrix} = \begin{bmatrix} 2 \\ -1 \end{bmatrix}$$

Τελικό αποτέλεσμα

$$x^* = (2, -1) \quad (\text{σε ένα μόνο βήμα}) \quad f(x^*) = -6$$

Γιατί ένα βήμα;

- Η f είναι τετραγωνική συνάρτηση (βαθμού 2).
- Ο Εσσιανός H_f είναι σταθερός και θετικά ορισμένος.
- Η μέθοδος Newton βρίσκει το ελάχιστο σε ένα βήμα για κάθε τετραγωνική συνάρτηση με θετικά ορισμένο Εσσιανό.

Προβλήματα μεθόδου Newton

- 1 **Εξάρτηση από το αρχικό σημείο:** Η Newton παρουσιάζει πολύ γρήγορη σύγκλιση όταν το x_0 βρίσκεται αρκετά κοντά σε ένα τοπικό ελάχιστο.
- 2 **Ο Εσσιανός μπορεί να μην είναι θετικά ορισμένος.**
- 3 **Υψηλό υπολογιστικό κόστος,** Ο Εσσιανός περιέχει n^2 στοιχεία και απαιτεί δεύτερες παραγώγους. Επιπλέον σε κάθε επανάληψη απαιτείται επίλυση του:
$$Hf(x_\kappa)\Delta x_\kappa = -\nabla f(x_\kappa)$$
 το οποίο θέλει $O(n^3)$ πράξεις.
- 4 **Οι δεύτερες παράγωγοι μπορεί να μην είναι διαθέσιμες,** Σε πολλά πραγματικά προβλήματα ο ακριβής Εσσιανός είναι δύσκολο ή ακριβό να υπολογιστεί.

- ❶ Η BFGS (Broyden–Fletcher–Goldfarb–Shanno) είναι μέθοδος Quasi-Newton.
- ❷ Αντί να υπολογίζει τον πραγματικό Εσσιανό, κατασκευάζει διαδοχικές προσεγγίσεις: $B_k \simeq H_f(x_k)$
- ❸ Ξεκινάμε συνήθως: $B_0 = I$ και μετά από κάθε βήμα ορίζουμε $s_k = x_{k+1} - x_k$ και $y_k = \nabla f(x_{k+1}) - \nabla f(x_k)$.
- ❹ Η ενημέρωση της προσέγγισης του Εσσιανού μπορεί να γραφτεί:


$$B_{k+1} = B_k - \frac{B_k s_k s_k^T B_k}{s_k^T B_k s_k} + \frac{y_k y_k^T}{y_k^T s_k}$$

με την προϋπόθεση ότι: $y_k^T s_k > 0$

Τα βήματα της μεθόδου BFGS

- ❶ **Αρχικοποίηση:** $x_0 \in S$, $B_0 = I$, $k = 0$.
- ❷ **Σε κάθε επανάληψη:**
 - ❶ $g_k = \nabla f(x_k)$.
 - ❷ Υπολογίζουμε το p_k με επίλυση $B_k p_k = -g_k$
 - ❸ Γραμμική αναζήτηση για $\alpha_k = \arg \min_{a>0} f(x_k + a p_k)$
 - ❹ Ενημέρωση: $x_{k+1} = x_k + \alpha_k p_k$
 - ❺ Υπολογισμός: $s_k = x_{k+1} - x_k$, $y_k = \nabla f(x_{k+1}) - \nabla f(x_k)$
 - ❻ Χρήση s_k, y_k για την ενημέρωση του
$$B_{k+1} = B_k - \frac{B_k s_k s_k^T B_k}{s_k^T B_k s_k} + \frac{y_k y_k^T}{y_k^T s_k}$$
- ❸ Ενημέρωση: $k = k + 1$

Η μέθοδος BFGS (διάγραμμα ροής)



Ιακωβιανός πίνακας

- Έστω η διανυσματική συνάρτηση $f = [f_1, f_2, \dots, f_m]$, πχ σε προσαρμογή δεδομένων.
- Ο **Ιακωβιανός** πίνακας ορίζεται ως

$$J_f(x) = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \cdots & \frac{\partial f_1}{\partial x_n} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} & \cdots & \frac{\partial f_2}{\partial x_n} \\ \vdots & \vdots & \vdots & \vdots \\ \frac{\partial f_m}{\partial x_1} & \frac{\partial f_m}{\partial x_2} & \cdots & \frac{\partial f_m}{\partial x_n} \end{bmatrix}$$

- Ο Ιακωβιανός περιέχει όλες τις πρώτες μερικές παραγώγους.
- **Παράδειγμα:**

$$f(x_1, x_2) = \begin{bmatrix} x_1^2 + x_2 \\ \sin x_1 + x_2^2 \end{bmatrix}, \quad J_f(x) = \begin{bmatrix} 2x_1 & 1 \\ \cos x_1 & 2x_2 \end{bmatrix}$$

Μέθοδος Levenberg–Marquardt

- 1 Στην μέθοδο Newton ο Εσσιανός πρέπει να είναι θετικά ορισμένος.
- 2 Αν όμως ο H_k δεν είναι θετικά ορισμένος, η κατεύθυνση Newton δεν είναι απαραίτητα κατεύθυνση καθόδου.
- 3 Η Levenberg–Marquardt τροποποιεί τον Εσσιανό προσθέτοντας έναν θετικό όρο στη διαγώνιο: $H_k + \lambda_k I$ και το βήμα υπολογίζεται από:

$$(H_k + \lambda_k I) \Delta x_k = -\nabla f(x_k)$$

με $\lambda_k > 0$ (παράμετρος απόσβεσης).


- 4 **Ρόλος της παραμέτρου απόσβεσης:** Για μικρές τιμές της η μέθοδος συμπεριφέρεται περισσότερο σαν Newton ($H_k + \lambda_k I \simeq H_k$). Για μεγάλες τιμές η συμπεριφορά της πλησιάζει την Gradient Descent

$$\left((H_k + \lambda_k I)^{-1} \simeq \frac{1}{\lambda_k} I \Rightarrow \Delta x_k \simeq -\frac{1}{\lambda_k} \nabla f(x_k) \right)$$

Προσαρμογή της παραμέτρου λ

- 1 Σε κάθε επανάληψη υπολογίζουμε το βήμα:
 $(H_k + \lambda_k I) \Delta x_k = -\nabla f(x_k)$ και το νέο σημείο
 $x_{new} = x_k + \Delta x_k$ και συγκρίνουμε $f(x_{new})$ με $f(x_k)$
- 2 Αν το βήμα είναι επιτυχημένο (μικρότερη τιμή συνάρτησης):
 $x_{k+1} = x_{new}$ και $\lambda_{k+1} = \frac{\lambda_k}{v}$, $v > 1$
- 3 Αν το βήμα αποτύχει (μεγαλύτερη τιμή συνάρτησης):
 $\lambda_{k+1} = v\lambda_k$, $v > 1$.

Διάγραμμα ροής για την προσαρμογή του λ .



Εφαρμογή σε προβλήματα ελαχίστων τετραγώνων

- Το πρόβλημα ορίζεται ως

$$\min_x \sum_{i=1}^m (r_i(x))^2$$

- Η παράγωγος δίνεται από:

$$\nabla f(x_i) = 2 \sum_{j=1}^m r_j(x) \frac{\partial r_j(x)}{\partial x_i}$$

- Με χρήση του Ιακωβιανού πίνακα:

$$\nabla f(x) = 2J_r(x)^T r(x)$$

Ο Εσσιανός υπο προϋποθέσεις μπορεί να γραφεί ως:

$$H_f(x) \simeq 2J_r(x)^T J_r(x)$$

- Επομένως

$$x_{k+1} = x_k - \left(J_r(x_k)^T J_r(x_k) + \mu_k I \right)^{-1} J_r(x_k)^T r(x_k)$$


Προσαρμογή δεδομένων

- 1 Στην γενική μορφή υπάρχουν μια σειρά από δεδομένα (x_i, y_i) , $i = 1, \dots, M$ από μια άγνωστη συνάρτηση.
- 2 Στόχος είναι να βρούμε ένα παραμετρικό μοντέλο: $\hat{y} = m(x; \theta)$ που να προσεγγίζει καλά τα δεδομένα.
- 3 Για κάθε σημείο ορίζουμε το σφάλμα:
 $r_i(\theta) = y_i - m(x_i; \theta)$ και αναζητούμε τις παραμέτρους θ που ελαχιστοποιούν το συνολικό σφάλμα

$$E(\theta) = \sum_{i=1}^M (y_i - m(x_i; \theta))^2$$

δηλαδή πρόβλημα ελαχίστων τετραγώνων.


Προσαρμογή δεδομένων (σχηματικά)



$$E(\theta) = \sum_{i=1}^M [y_i - m(x_i; \theta)]^2$$

Στόχος: να βρούμε τις παραμέτρους θ ώστε το μοντέλο να προσεγγίζει καλά τα δεδομένα.

Παράδειγμα Data Fitting



Το μοντέλο $\hat{y} = m(x; \theta^*)$ προσεγγίζει καλά τα δεδομένα και μπορεί να εκτιμήσει τη συνάρτηση και σε νέα σημεία.

Προσαρμογή δεδομένων με πολυώνυμο

- Διαθέτουμε δεδομένα (x_i, y_i) , $i = 1, \dots, M$
- Δημιουργείται ένα πολυώνυμο βαθμού $k < M$
- Το πολυώνυμο δίνεται από τον τύπο:

$$p_k(x) = a_k x^k + a_{k-1} x^{k-1} + \dots + a_0$$

- Οι άγνωστες παράμετροι είναι: $\theta = (a_0, a_1, \dots, a_k)$
- Ελαχιστοποιούμε το σφάλμα:


$$E(\theta) = \sum_{i=1}^M (y_i - p_k(x_i))^2$$

ως προς το σύνολο παραμέτρων θ .

Προσαρμογή με πολυώνυμο (σχήμα)

Προσαρμογή δεδομένων με πολυώνυμο


(α) Χαμηλός βαθμός ($k = 1$)
Υπεραπλοποίηση (Underfitting)



Το μοντέλο είναι πολύ απλό
και δεν περιγράφει καλά τα δεδομένα.

$E(\theta^*)$ μεγάλο


(β) Κατάλληλος βαθμός ($k = 3$)
Καλή προσαρμογή



Το μοντέλο περιγράφει καλά τα δεδομένα
χωρίς υπερβολική πολυπλοκότητα.

$E(\theta^*)$ μικρό

(γ) Πολύ υψηλός βαθμός ($k = 9$)
Υπερπροσαρμογή (Overfitting)



Το μοντέλο προσαρμόζεται σχεδόν ακριβώς
στα δεδομένα, αλλά μπορεί να έχει κακή
συμπεριφορά σε νέα σημεία.

$E(\theta^*)$ πολύ μικρό
(μηδέν αν $k \geq M - 1$)

Μικρή πολυπλοκότητα
(μεγάλη προκατάληψη)

Βαθμός πολυωνύμου k

Μεγάλη πολυπλοκότητα
(μεγάλη διακύμανση)

Συνάρτηση σφάλματος σε πολυώνυμο

- Ελαχιστοποίηση της $E(p_k(x)) = \sum_{i=1}^M (y_i - p_k(x_i))^2$ με άγνωστους τα στοιχεία a_i , $i = 1, \dots, k$
- Μερικές παράγωγοι:

$$\frac{\partial E}{\partial a_j} = 2 \sum_{i=1}^M (y_i - p_k(x_i)) (-x_i^j)$$

Τεχνητό νευρωνικό δίκτυο

- Ένα τεχνητό νευρωνικό δίκτυο είναι ένα παραμετρικό μοντέλο, όπως και το πολυώνυμο, αλλά με μεγαλύτερη ευελιξία: $\hat{y} = N(x; \theta)$ όπου το διάνυσμα παραμέτρων $\theta = (w_1, w_2, \dots, w_P)$ περιλαμβάνει τα βάρη και τις πολώσεις του ΤΝΔ.
- Μια μορφή εξίσωσης των τεχνητών νευρωνικών δικτύων μπορεί να είναι:


$$N(\vec{x}, \vec{w}) = \sum_{i=1}^H w_{(d+2)i-(d+1)} \sigma \left(\sum_{j=1}^d x_j w_{(d+2)i-(d+1)+j} + w_{(d+2)i} \right)$$

- Η ποσότητα $w_{(d+2)i}$ ονομάζεται πόλωση.
- Η συνάρτηση $\sigma(x)$ είναι η σιγμοειδής συνάρτηση με τύπο:

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

Νευρωνικά δίκτυα (σχήμα)

Τεχνητό Νευρωνικό Δίκτυο



Έξοδος νευρωνικού δικτύου (όπως στις σημειώσεις):

$$N(\vec{x}, \vec{w}) = \sum_{i=1}^H w_{(d+2)i-(d+1)} \sigma \left(\sum_{j=1}^d x_j w_{(d+2)i-(d+1)+j} + w_{(d+2)i} \right)$$

Συνάρτηση ενεργοποίησης (σιγμοειδής):

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

Συνάρτηση σφάλματος (data fitting):

$$E(\vec{w}) = \sum_{i=1}^M [y_i - N(\vec{x}_i, \vec{w})]^2$$

Εκπαίδευση (βελτιστοποίηση):

$$\vec{w}^* = \arg \min_{\vec{w}} E(\vec{w})$$

- Κόμβος εισόδου x_j
- Κρυφός νευρώνας $\sigma(\cdot)$
- Κόμβος εξόδου (γραμμικός συνδυασμός)
- Πόλωση (bias) b_i

Το νευρωνικό δίκτυο είναι ένα παραμετρικό μοντέλο, όπως το πολυώνυμο, αλλά με μεγαλύτερη ευελιξία στην προσέγγιση πολύπλοκων συναρτήσεων.

Σύγκριση μεθόδων βελτιστοποίησης

Σύγκριση μεθόδων βελτιστοποίησης

Οι μέθοδοι που εξετάσαμε χρησιμοποιούν διαφορετική πληροφορία και έχουν διαφορετικά χαρακτηριστικά.

Μέθοδος	Gradient (1 ^{ος} παράγωγοι)	Hessian (2 ^{ος} παράγωγοι)	Τυπικό κόστος ανά επανάληψη	Κύριο χαρακτηριστικό	Πλεονεκτήματα	Μειονεκτήματα
Gradient Descent (GD)	✓	✗	Χαμηλό	Απλή μέθοδος πρώτης τάξης	- Απλή υλοποίηση - Μικρό υπολογιστικό κόστος - Κατάλληλη για μεγάλα προβλήματα	- Αργή σύγκλιση - Ευαισθητή στην επιλογή βήματος - Μπορεί να παγιδευτεί σε τοπικά ελάχιστα
Newton	✓	✓	Υψηλό	Μέθοδος δεύτερης τάξης	- Πολύ γρήγορη σύγκλιση κοντά στο ελάχιστο - Ακριβής χρήση καμπυλότητας	- Απαιτεί υπολογισμό/αντιστροφή Hessian - Υψηλό υπολογιστικό κόστος - Μπορεί να αποτύχει αν ο Hessian δεν είναι θετικά ορισμένος
BFGS	✓	✗	Μέτριο	Quasi-Newton (προσεγγίζει τον Hessian)	- Δεν απαιτεί 2^{ος} παραγώγους - Καλή ταχύτητα σύγκλισης - Σταθερή και αξιόπιστη	- Περισσότερη μνήμη - Μπορεί να είναι πιο αργή από τη Newton
Levenberg–Marquardt (LM)	✓	✗ *	Μέτριο	Ειδική μέθοδος για μη γραμμικά ελάχιστα τετράγωνα	- Πολύ αποτελεσματική για data fitting - Συνδυάζει Gauss–Newton και gradient descent - Σταθερή σύγκλιση	- Εφαρμόζεται κυρίως σε προβλήματα least squares - Απαιτεί Jacobian - Μπορεί να είναι αργή αν το πρόβλημα δεν είναι κατάλληλο

* Στη μέθοδο Levenberg–Marquardt δεν υπολογίζεται άμεσα ο Hessian, αλλά χρησιμοποιείται ο Jacobian για την προσέγγιση $J^T J$.

Gradient Descent	→	χαμηλό κόστος / απλότητα
Newton	→	2ες παράγωγοι / γρήγορη τοπική σύγκλιση
BFGS	→	προσέγγιση Hessian
Levenberg–Marquardt	→	Least Squares / Data Fitting

Συνοπτικά

- Δεν υπάρχει μία μέθοδος που να είναι καλύτερη για όλα τα προβλήματα.
- Η επιλογή μεθόδου εξαρτάται από τη φύση του προβλήματος, το κόστος υπολογισμού και τη διαθεσίμη πληροφορία (παράγωγο).
- Για προβλήματα προσαρμογής δεσμών (least squares) η Levenberg-Marquardt είναι συχνά η πιο αποτελεσματική επιλογή.

Η σωστή μέθοδος εξαρτάται από το συγκεκριμένο πρόβλημα και τους υπολογιστικούς περιορισμούς.

Σύνοψη

Σύνοψη – Από τις παραγώγους στην προσαρμογή δεδομένων

1. Πρόβλημα βελτιστοποίησης

$$\min_{x \in \mathbb{R}^n} f(x)$$

- Βρίσκουμε το x^* που ελαχιστοποιεί την αντικειμενική συνάρτηση $f(x)$.
- Οι παράγωγοι δίνουν πληροφορία για την κατεύθυνση και την καμπυλότητα.

2. Παράγωγοι και πληροφορία

Gradient
 $\nabla f(x)$

Δείχνει την κατεύθυνση της μεγαλύτερης αύξησης. $(H - \nabla f(x))$ είναι κατεύθυνση καθόδου.)

Hessian
 $H_f(x)$

Περιγράφει την καμπυλότητα (2ος παράγωγος).

Jacobian
 $J_f(x)$

Για διανυσματικές συναρτήσεις (π.χ. προβλήματα ελαχίστων τετραγώνων).

3. Προσαρμογή δεδομένων (data fitting)

Δεδομένα: $\{(x_i, y_i)\}_{i=1}^M$

Παραμετρικό μοντέλο: $m(x; \theta)$

$$E(\theta) = \sum_{i=1}^M [y_i - m(x_i; \theta)]^2$$

- Η προσαρμογή δεδομένων είναι πρόβλημα βελτιστοποίησης:
 $\theta^* = \arg \min_{\theta} E(\theta)$
- Διαφορετικές επιλογές μοντέλου οδηγούν σε διαφορετική ευελξία.

4. Μέθοδοι βελτιστοποίησης



Gradient Descent (GD) $x_{k+1} = x_k - \alpha \nabla f(x_k)$

Newton $x_{k+1} = x_k - [H_f(x_k)]^{-1} \nabla f(x_k)$

BFGS (Quasi-Newton) $x_{k+1} = x_k - H_k \nabla f(x_k)$
(προσέγγιση του Hessian)

Levenberg-Marquardt $(J^T J + \lambda I) \Delta = -J^T r$
(για μη γραμμικά ελάχιστα τετράγωνα)

5. Ενδεικτικά μοντέλα για data fitting



6. Συνολική ροή

Πρόβλημα
(δεδομένα ή άλλη εφαρμογή)



Παράγωγοι
 $\nabla f, H_f, J_f$



Μέθοδος
βελτιστοποίησης
(GD, Newton, BFGS, LM)



Εύρεση βέλτιστου
(παραμέτρων x ή θ)



Προσαρμοσμένο μοντέλο
(πολύωνυμο, νευρωνικό, κλπ.)

Η βελτιστοποίηση αποτελεί το ενιαίο πλαίσιο που συνδέει τις παραγώγους με την προσαρμογή δεδομένων και την εκπαίδευση παραμετρικών μοντέλων.